

# Indice

# 1 Operazioni sui linguaggi

Visto che un linguaggio  $L \subseteq \Sigma^*$  è un sottoinsieme di un insieme, possiamo fare tutte le operazioni insiemistiche su un linguaggio:

- intersezione  $L \cap L'$
- unione  $L \cup L'$
- complemento  $L^C$ . Si può pensare di calcolare il complemento di un linguaggio  $L \subseteq \Sigma^*$  rispetto ad un alfabeto più grande  $\Sigma \subseteq \Gamma$ . Il complemento è esattamente  $\Gamma^* \setminus L$ .

Definiamo il prodotto di due linguaggi  $L', L'' \subseteq \Sigma^*$

$$L' \cdot L'' = \{z \mid \exists x \in L' \exists y \in L''. z = xy\}$$

E se  $L' \subseteq \Sigma'^*$ ,  $L'' \subseteq \Sigma''^*$ , allora  $L' \cdot L'' \subseteq \Sigma' \cup \Sigma''$ . Salvo casi particolari (e.g. alfabeto da una lettera sola) questa operazione non è commutativa. E vale  $\{\epsilon\}$  è l'identità destra e sinistra, e  $\emptyset$  è l'elemento nullo destro e sinistro.

Definiamo la potenza di un linguaggio

$$L^k = \underbrace{L \cdot L \dots}_{k \text{ volte}}$$

e vale che

$$L^0 = \{\epsilon\}$$

ovvero il linguaggio ottenuto concatenando zero parole di  $L$ . Il prodotto e la potenza di un linguaggio finito sono ancora finiti.

Definiamo la chiusura di Kleene di un linguaggio

$$L^* = \bigcup_{k \geq 0} L^k$$

La chiusura di Kleene anche di un linguaggio finito è finito.

$$\begin{aligned} L &= \{a, bb\}^* \\ &= \{x \in \{a, b\}^* \mid \text{Ogni fattore massimale di } b \text{ è di lunghezza pari} \} \end{aligned}$$

Dove massimale indica che non può essere allungato.

Vale inoltre che

$$\{\epsilon\}^* = \{\epsilon\}$$

e che

$$\emptyset^* = \{\epsilon\}$$

Definiamo la chiusura di Kleene positiva di un linguaggio

$$L^+ = \bigcup_{k \geq 1} L^k$$

Inoltre vale che  $L$  non contiene la parola vuota, allora  $L^+$  a sua volta non la contiene, e questo è uguale a  $L^+ = L^* \setminus \{\epsilon\}$ . Nota bene, non vale che generalmente  $L^+ = L^* \setminus \{\epsilon\}$ .

**Fatto 1.**

$$L \cdot L^* = L \bigcup_{k \geq 0} L^k = \bigcup_{k \geq 0} LL^k = \bigcup_{k \geq 1} L^k = L^+ = L^* \cdot L$$

## 2 Espressioni regolari

Le espressioni regolari sono in un certo senso una descrizione dichiarativa di un linguaggio. Dato un alfabeto  $\Sigma$ , definiamo ricorsivamente le espressioni regolari come

- $\emptyset$ , rappresenta il linguaggio vuoto
- $\epsilon$ , rappresenta il linguaggio della parola vuota
- $a \in \Sigma$ , rappresenta il linguaggio di solo  $a$

ora definiamo

- $E_1 + E_2$ , rappresenta il linguaggio  $L(E_1) \cup L(E_2)$
- $E_1 \cdot E_2$ , rappresenta il linguaggio  $L(E_1) \cdot L(E_2)$
- $E^*$ , rappresenta il linguaggio  $L(E)^*$

L'espressione regolare

$$(a + bb)^*$$

rappresenta il linguaggio  $\{a, bb\}^*$ .

Il linguaggio dove il terzultimo simbolo è una  $a$  è rappresentato dall'espressione regolare

$$(a + b)^*a(a + b)(a + b)$$

E volendo generalizzare al linguaggio il cui  $n$ -esimo simbolo da destra è una  $a$

$$(a + b)^*a(a + b)^n$$

Dove le potenze sulle espressioni regolari rappresentano una serie di prodotti.

Il linguaggio dove due simboli a distanza  $n$  sono uguali

$$((a + b)^*a(a + b)^{n-1}a(a + b)^*) + ((a + b)^*b(a + b)^{n-1}b(a + b)^*)$$

Questo può essere semplificato in

$$(a + b)^*((a(a + b)^{n-1}a) + (b(a + b)^{n-1}b))(a + b)^*$$

**Definizione 1** (State complexity). *Definiamo la complessità di stati o state complexity di un linguaggio  $L \subseteq \Sigma^*$ , indicata  $sc(L)$ , come il minimo numero di stati del DFA che accetta  $L$ . E definiamo la non-deterministic state complexity, indicata con  $nsc(L)$ , come il minimo numero di stati del NFA che accetta  $L$ .*

**Fatto 2.**

$$sc(L) \leq 2^{nsc(L)}$$

Dato  $L_n = (a + b)^*a(a + b)^{n-1}$ , vale che  $\text{nsc}(L_n) \leq n + 1$ , mentre  $\text{sc}(L_n) \geq 2^n$ , e visto che per questo linguaggio sappiamo costruire un automa da  $2^n$  stati, allora  $\text{sc}(L_n) = 2^n$ .

La stringa più corta di questa linguaggio è la stringa che inizia con  $a$  ed ha  $n$  simboli. Supponendo di avere meno di  $n$  stati, allora ce ne deve essere almeno uno che si ripete; quindi c'è un loop. Se io elimino il loop potrei riconoscere una stringa più breve di quella più breve.

Quindi abbiamo che per forza  $\text{nsc}(L_n) = n + 1$ .

Alternativamente si può costruire il fooling set composto da tutte le possibili scomposizioni in due stringhe di  $ab^{n-1}$ .

**Proposizione 1.** *Preso la stringa più corta del linguaggio, ogni NFA deve per forza avere  $n + 1$  stati, dove  $n$  sono i simboli della stringa.*

**Teorema 1** (Teorema di Kleene o Teorema fondamentale degli automi a stati finiti). *La classe dei linguaggi accettati da automi a stati finiti è la più piccola sottoinsieme di  $\Sigma^*$  che contiene i linguaggi finiti ed è chiusa rispetto alle operazioni di unione, prodotto e chiusura di Kleene.*

Quindi la classe degli automi a stati finiti coincide con la classe esprimibile dalle espressioni regolari.

*Dimostrazione.* Dimostriamo il primo lato, passandoci da un automa ad una regex. Dato un automa

$$\mathcal{A} = \langle Q, \Sigma, \delta, q_1, F \rangle$$

e supponiamo che gli stati siano numerati da uno ad  $n$

$$Q = \{q_1, q_2, \dots, q_n\}$$


possiamo vedere come il linguaggio come tutti i cammini dallo stato iniziale agli stati finali, e che concatenando le etichette del cammino otteniamo un parola accettata dal percorso. le etichette del cammino otteniamo un parola accettata dal percorso.

Costruiamo un algoritmo simile a quello di Floyd-Warshall che trova tutti i cammini minimi. Chiamiamo  $R_{ij}^{(k)}$  l'insieme di tutti i percorsi da  $q_i$  a  $q_j$  che passano solo per stati con indice minore di  $k$ . Quando metteremo  $k = n$  avrò trovato tutte le stringhe da  $i$  a  $j$ . Andando per induzione definiamo l'insieme come

- $R_{ij}^{(0)}$  è il caso in cui c'è una transizione tra lo stato  $i$  e lo stato  $j$ .

$$R_{ij}^{(0)} = \begin{cases} \{\alpha \in \Sigma \mid \delta(q_i, \alpha) = q_j\} & \text{se } i \neq j \\ \{\epsilon\} \cup \{\alpha \in \Sigma \mid \delta(q_i, \alpha) = q_i\} & \text{se } i = j \end{cases}$$

- supponiamo di avere  $R_{ij}^{(k-1)}$ , voglio trovare  $R_{ij}^{(k)}$ . Cerco tutti i punti per cui il nuovo cammino passa per  $q_k$ , nelle sezioni tra i  $q_k$  gli stati intermedi sono tutti minori di  $k$ .



Quindi


$$R_{ij}^{(k)} = R_{ij}^{(k-1)} \cup R_{ik}^{(k-1)} \left( R_{kk}^{(k-1)} \right)^* R_{kj}^{(k-1)}$$

Con  $k = n$  abbiamo tutti i percorsi e vale che

$$L = \bigcup_{q_i \in F} R_{1i}^{(n)}$$

Dimostriamo il secondo lato, passandoci da una regex ad un automa. ■

Mostriamo una tecnica diversa per generare la regex da un automa.



Costruiamo un sistema di equazioni per ogni stato


$$\begin{cases} X &= aX_1 + bY \\ Y &= \epsilon \end{cases}$$

e sostituendo

$$\begin{cases} X &= aX + b \\ Y &= \epsilon \end{cases}$$

se ci troviamo in uno stato  $X = AX + B$ , questo corrisponde alla regex  $A^*B$ . Questo è banalmente  $a^*b$ .

Un altro esempio più complesso



Costruiamo un sistema di equazioni per ogni stato

$$\begin{cases} X_0 &= aX_1 + bX_0 \\ X_1 &= aX_2 + bX_0 \\ X_2 &= aX_2 + bX_1 + \epsilon \end{cases}$$

$\epsilon$  perché  $X_2$  è finale. Sostituendo  $X_1$  abbiamo

$$\begin{aligned} X_0 &= aaX_2 + abX_0 + bX_0 \\ &= aaX_2 + (ab + b)X_0 \end{aligned}$$

e

$$\begin{aligned} X_2 &= aX_2 + baX_2 + bbX_0 + \epsilon \\ &= (a + ba)X_2 + bbX_0 + \epsilon \\ &= (a + ba)^* + bbX_0 + \epsilon \end{aligned}$$

che corrisponde alla regex  $(a + ba)^*(bbX_0 + \epsilon)$ , prendendo come  $A = (a + ba)$  e  $B = (bbX_0 + \epsilon)$ . E sostituendo ancora

$$\begin{aligned} X_0 &= aaX_2 + (ab + b)X_0 \\ &= aa(a + ba)^*(bbX_0 + \epsilon) + (ab + b)X_0 \\ &= (aa(a + ba)^*bb + ab + b)X_0 + aa(a + ba)^* \end{aligned}$$

che quindi è  $(aa(a + ba)^*bb + ab + b)^* + aa(a + ba)^*$ .

Il complemento di linguaggio riconosciuto da un automa deterministico è banalmente il complemento dell'insieme dei finali.